

**Relatório de Validação e Benchmarking:**  
*Task 1 – Otimização do Modelo de Volatilidade (LightGBM)*

**Elaborado por:** Pedro Henrique Vogt Verolla  
**Data:** Maio de 2026

### Resumo

Este documento detalha os resultados da **Task 1: Benchmarking e Validação Relativa**, cujo objetivo é validar o *alpha* gerado pela arquitetura baseada em LightGBM frente a modelos econométricos clássicos (GARCH) e métodos ingênuos (Random Walk). Os testes foram conduzidos em múltiplos ativos (BTC-USD, PETR4, VALE3 e IBOV). Os resultados demonstram altíssima superioridade do Machine Learning em ativos com volatilidade de cauda longa (Cripto), porém revelam vulnerabilidades de *overfitting* e excesso de ruído preditivo no mercado acionário brasileiro de curto prazo.

## 1 Introdução e Metodologia

No desenvolvimento de ferramentas de Data Science aplicadas ao mercado financeiro, a complexidade algorítmica só é justificada se for capaz de superar a inércia do mercado e a literatura econométrica estabelecida. Para validar a eficácia do *Volatility Predictor*, estruturou-se uma competição de modelos considerando duas linhas de base (benchmarks):

- Modelo Naive (Random Walk):** Assume que a melhor previsão para a volatilidade futura em  $T + 5$  é a volatilidade observada no período atual  $T$ .
- Modelo GARCH(1,1):** Modelo clássico de variância condicional. A variância é modelada conforme a Equação 1:

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \quad (1)$$

O ganho relativo (*Alpha*) foi calculado comparando o Erro Quadrático Médio (RMSE) do LightGBM com os benchmarks. Adicionalmente, implementou-se um filtro de **Bear Market** para isolar a performance dos modelos durante janelas de estresse e pânico direcional (identificadas por retornos extremos do IBOV e quartis superiores de volatilidade).

Tabela 1: Performance Geral (RMSE) e Alpha Relativo

| Ativo   | Naive          | GARCH(1,1) | LightGBM       | Alpha (vs Naive) | Alpha (vs GARCH) |
|---------|----------------|------------|----------------|------------------|------------------|
| BTC-USD | 0.07276        | 0.14424    | <b>0.06703</b> | + 7.9%           | + 53.5%          |
| VALE3   | <b>0.03695</b> | 0.10419    | 0.04245        | - 14.9%          | + 59.3%          |
| BVSP    | <b>0.02049</b> | 0.05292    | 0.02429        | - 18.5%          | + 54.1%          |
| PETR4   | <b>0.04768</b> | 0.13637    | 0.08230        | - 72.6%          | + 39.7%          |

## 2 Resultados Empíricos

A Tabela 1 sumariza o RMSE de todos os modelos no período completo de \*backtest\*, bem como o ganho relativo percentual do LightGBM sobre os concorrentes.

A Tabela 2 detalha a resiliência dos modelos exclusivamente durante dias classificados como *Bear Market*.

Tabela 2: Teste de Estresse: Bear Market (Janelas de Pânico)

| Ativo   | Naive          | GARCH(1,1) | LightGBM       | Alpha (vs Naive) | Alpha (vs GARCH) |
|---------|----------------|------------|----------------|------------------|------------------|
| BTC-USD | 0.09518        | 0.11683    | <b>0.08235</b> | + 13.5%          | + 29.5%          |
| VALE3   | <b>0.04387</b> | 0.06726    | 0.04856        | - 10.7%          | + 27.8%          |
| BVSP    | <b>0.02473</b> | 0.03056    | 0.03113        | - 25.9%          | - 1.9%           |
| PETR4   | <b>0.06565</b> | 0.11915    | 0.13381        | - 103.8%         | - 12.3%          |

## 3 Discussão e Diagnóstico

A análise dos resultados evidencia uma bifurcação drástica no comportamento do modelo dependendo da natureza do ativo subjacente, trazendo à tona conceitos fundamentais sobre hipótese de eficiência de mercado e *feature engineering*.

### 3.1 O Sucesso em Criptoativos (BTC-USD)

O LightGBM provou ser o modelo definitivo para a volatilidade do Bitcoin. O GARCH tradicional falha sistematicamente (-53.5% de precisão) por assumir distribuições mais normais, não conseguindo capturar os saltos caóticos e as caudas grossas características do ecossistema cripto. Mais importante ainda, o ganho de Alpha sobre o modelo Naive  **aumentou** de 7.9% para 13.5% durante o Bear Market, provando que a arquitetura possui valor preditivo prático para proteção de portfólios em momentos de crise.

### 3.2 O Desafio da B3 (Ações e Índices)

Nos ativos brasileiros (PETR4, VALE3 e IBOV), o modelo Naive dominou as métricas de acurácia. Este fenômeno não reflete um defeito no algoritmo, mas sim características estruturais do mercado de capitais:

- **Inércia e Eficiência:** O índice Bovespa ( $\widehat{BVSP}$ ) é altamente suavizado. A probabilidade da volatilidade de curto prazo (5 dias) permanecer idêntica à de hoje é estatisticamente esmagadora. O LightGBM tenta prever reversões complexas onde existe apenas ruído, penalizando seu RMSE.
- **Choques Exógenos e Risco Político:** O caso da PETR4 (erro 103% maior que o Naive no Bear Market) ilustra a vulnerabilidade do modelo a choques exógenos. As *features* atuais estão tentando encontrar um padrão técnico linear para precificar eventos que ocorrem fora do pregão (ex: mudanças em diretoria ou declarações políticas em Brasília).
- **Multicolinearidade e Lixo Preditivo:** Modelos de gradiente como o LightGBM, quando alimentados com dezenas de indicadores técnicos (*RSI*, *Parkinson*, *Skewness*) e limitados por regimes de mercado longos, tendem a realizar *overfitting*, decorando o passado em vez de extrair sinais macroeconômicos reais.

## 4 Conclusão e Próximos Passos

O *Benchmarking* cumpriu seu papel diagnóstico. A arquitetura validou seu *Alpha* em ambientes de altíssima não-linearidade (Cripto), mas requer refatorações críticas para aplicações no mercado acionário clássico. Para viabilizar a utilização da ferramenta em ativos da B3 na próxima etapa do projeto, as seguintes implementações (já mapeadas) são obrigatórias:

1. **Descoberta de Features e SHAP (Task 3):** Eliminar sumariamente *features* com fator de inflação da variância ( $VIF > 10$ ) e utilizar análise de *Shapley Values* para expurgar indicadores que estão gerando falsos positivos na B3.
2. **Governança contra Overfitting (Task 4):** Adicionar termos de regularização *L1* (Lasso) e *L2* (Ridge) na função de custo do Optuna e restringir estruturalmente a profundidade das árvores, forçando o modelo a respeitar a inércia do mercado de ações.